

研究计划

面向科研与社会行为的人本智能系统研究：行为证据、可信建模与群体福利优化

申请人	樊光瑞
拟申请单位	深圳理工大学人工智能研究院“智能与行为交叉研究中心”
拟申请岗位	特聘副教授
计划周期	入职后 3 - 5 年

一、研究愿景与总体定位

人工智能正在从单一工具转变为嵌入科研生产、教育学习、社会沟通、平台治理和资源分配过程的基础性社会技术系统。随之而来的核心科学问题，不再只是模型能否生成更准确的结果，而是：当 AI 深度参与人的知识生产、判断、协作与选择时，人类行为如何被改变；这些行为证据如何被计算模型可靠表达；以及如何在效率、公平、信任与群体福利之间建立可解释、可审计、可部署的智能系统。

深圳理工大学人工智能研究院“智能与行为交叉研究中心”强调文、理、工交叉范式，聚焦 AI 与人类行为模式及效应的交叉研究，并在公开方向中突出“面向科研行为”的 AI Scientist、科研信息检索与整合、多科研主体交互、科研资源分配与科研评价，以及“面向人类社会行为”的群体行为、资源分配与效率等问题。我的研究计划拟在这一中心框架下发展一条具有清晰个人积累、可与中心方向深度协同、并具有长期增长空间的研究主线：面向科研与社会行为的人本智能系统研究。

该主线以 Human-Centered AI、人机交互、社会计算和可信机器学习为方法基础，以科研行为、学习行为、AI 介导沟通、隐私选择、群体反馈和资源分配为主要对象，形成“行为证据采集—计算模型构建—系统原型验证—群体福利评估”的闭环。与中心方向的关系不是简单重复，而是以可操作的 HCI 实证方法、LLM/Agent 系统、图学习、偏好学习、因果推断和公平性评估，为中心的 AI for Science 与 AI for Humanity 两条主线提供可落地的技术路线和实验平台。

二、已有基础与岗位匹配

我长期从事面向真实用户与社会场景的人本智能系统研究，将 HCI 实证研究与机器学习模型结合，关注 AI 如何被真实用户理解、评估、采纳、抵抗或误用。现有成果覆盖 AI 辅助编程教育、AI 介导沟通与信任、语言模型情感规范、隐私同意边界、公平偏好学习、网络采样反馈校正、在线心理健康社区、图神经网络与时空预测等方向。

截至目前，我以第一作者或通讯作者发表/录用包括 ACL、ICML、CHI、FSE、WWW、AAAI、IJCAI 等 CCF A 类会议论文 9 篇，以及中科院 1 区 Top 期刊论文 4 篇；其中 3 篇被 CHI 2026 录用，1 篇获得 ACM CHI 2026 Honourable Mention Award。发表于 International Journal of

STEM Education 的 AI 辅助结对编程研究论文已入选 ESI 高被引论文，并成为该刊近两年高被引文章之一。上述成果为本计划提供了三个方面的可行性基础。

第一，行为机制基础。我已有工作系统研究了 AI 辅助编程如何影响学习动机、编程焦虑、协作学习与学习表现，并进一步揭示 AI coding assistants 中 verification load and fatigue 的形成机制。这为研究 AI 进入科研、学习和知识生产过程后的认知负担、验证负担、信任校准和能力形成提供了直接基础。

第二，社会互动基础。我围绕 AI 辅助浪漫沟通中的作者归属与真实性判断、语言模型中的情感得体性规范、AI 生成摘要中的信任与理解、Web consent 中的同意边界与 opt-out friction 等问题，形成了 AI 介入沟通、情感表达、隐私选择与社会规范后的行为效应研究积累。

第三，计算建模基础。我在 Graph-Preference Learning、算法公平元评估、在线心理健康社区回复间隔预测、图神经网络交通预测、隐私保护心理健康筛查、分布无关推荐风险控制等方向开展了机器学习建模研究，能够将非均衡人类反馈、网络结构、群体偏好和目标福利估计纳入统一的可解释与可评估框架。

因此，我与该岗位的匹配点主要体现在：一是能够面向中心“科研行为”方向，研究 AI Scientist 在真实科研流程中的人因效应、验证机制和协作边界；二是能够面向中心“人类社会行为”方向，研究 AI 对学习、沟通、信任、隐私和群体反馈的影响；三是能够面向“群体行为—资源分配—效率评价”问题，发展公平偏好学习、行为建模和群体福利估计方法；四是具备从理论问题、算法模型、用户实验到系统原型的完整研究闭环。

三、核心科学问题与总体目标

本计划围绕“AI 参与科研与社会行为后的机制、模型与系统”展开，拟回答以下三个核心科学问题。

问题一：AI 如何改变人的知识生产、学习、沟通和判断过程？ 重点关注 AI 参与后人的注意力分配、认知负担、验证负担、创造性、信任校准、责任归属和能力形成机制，避免只以任务效率或模型分数衡量 AI 系统价值。

问题二：如何将真实场景中的人类行为证据转化为可靠、可解释、可审计的计算模型？ 真实反馈往往来自非均衡样本、社交网络、平台流量、制度约束或界面摩擦。需要将 HCI 实验、日志数据、问卷访谈、网络结构、偏好学习、因果推断和公平性约束结合起来，使模型既能解释个体行为，也能估计群体层面的福利与风险。

问题三：如何设计兼顾效率、公平、信任与群体福利的人本智能系统？ 在科研资源分配、AI 辅助学习、在线社区响应、隐私同意、AI 介导沟通和平台治理中，系统目标不能仅是平均性能最大化，还应考虑低可见度群体、沉默用户、弱势群体和制度性偏差，使 AI 决策具备更强的社会可接受性和可持续性。

围绕上述问题，入职后 3-5 年拟实现以下总体目标：

1. 建立“行为证据—计算建模—系统评估—福利优化”的人本智能研究框架，形成与中心 AI for Science 和 AI for Humanity 双主线相契合的稳定研究方向。

2. 构建面向科研行为的 AI Scientist 人因评估体系，解释 AI 科研助手在信息检索、证据整合、研究问题生成、实验设计、审稿与科研评价中的帮助、风险和协作边界。

3. 建立面向 AI 辅助学习、AI 介导沟通、隐私选择和群体反馈的行为实验与系统评估平台，形成可复用数据集、原型工具和评价指标。

4. 发展面向网络采样反馈、群体偏好和资源分配的公平机器学习方法，为科研资源分配、教育支持、在线社区响应与公共服务场景提供可审计的福利估计工具。

5. 形成具有国际辨识度的人本智能与行为计算研究团队，在 CHI、CSCW、ACL、WWW、FAccT、ICML、AAAI、FSE 以及中科院一区期刊持续产出高水平成果。

四、拟开展的研究方向

方向一：面向科研行为的 AI Scientist 人因评估与协作机制

中心公开方向将“提高科研信息检索与整合，构建辅助科研的 AI Scientist”作为面向科研行为的重要议题。现有 AI Scientist 研究多关注自动化生成、检索增强、Agent 工作流和基准分数，但真正决定其能否进入科研实践的关键，是研究者如何理解、验证、采纳或拒绝 AI 提供的证据与建议。科研活动具有高不确定性、高责任性和长周期反馈特征，AI 介入后可能提升文献整合与假设生成效率，也可能引入幻觉证据、确认偏误、过度依赖、创造性收敛和验证疲劳。

我拟以“科研行为中的 AI 协作、证据验证与信任校准”为核心，研究以下问题：

- 在文献检索、综述写作、研究问题生成、实验设计、论文修改和审稿意见回应等任务中，AI 辅助会如何改变研究者的注意力、创造性、证据检查和决策路径？
- AI Scientist 生成的文献链、论证链和实验建议应如何呈现，才能降低 verification load，而不是把隐性成本转移给研究者？
- 如何建立面向科研任务的人因评测指标，将证据准确性、可追溯性、认知负担、错误发现率、信任校准、创新性和可复现性纳入同一评价框架？
- 多科研主体交互背景下，AI 工具如何影响合作分工、信用归属、资源竞争和科研评价？如何避免 AI 强化既有可见度优势或评价偏差？

技术路线包括：（1）构建科研任务实验协议，覆盖文献综述、假设生成、证据验证、审稿判断和实验设计；（2）开发带有证据追踪、置信提示和可解释界面的 RAG/LLM/Agent 科研协作原型；（3）通过受控实验、真实科研任务部署、日志分析、眼动或交互行为指标、访谈和问卷测量 AI 介入后的行为机制；（4）利用因果推断、行为序列建模和不确定性估计，解释 AI 建议何时提升科研效率，何时削弱判断质量；（5）进一步将科研人评价与资源分配建模为多主体偏好与福利估计问题，为中心关于科研资源分配和科研评价的新方法提供方法支撑。

预期产出包括面向 CHI、CSCW、ACL、WWW、JASIST、TOCHI 等方向的论文，面向科研行为的人因评估数据集，AI Scientist 协作原型，以及“科研 AI 工具可信评估指标体系”。该方向能够直接服务中心 AI for Science 方向，也能与我的 AI 编程助手验证负担研究、LLM 交互评估和公平偏好学习积累自然衔接。

方向二：AI 辅助学习与知识能力形成机制

AI 编程助手和通用 LLM 正在快速进入高校课程与真实软件开发场景。它们可以降低初学者入门门槛、提升反馈效率，也可能诱发认知卸载、过度依赖、验证疲劳、能力错觉和学术诚信风险。与传统教育技术不同，生成式 AI 并非只提供固定资源，而是持续参与问题分解、代码生成、错误解释、反馈评价和学习路径推荐，因此需要重新研究“AI 时代学习能力如何形成”。

我的既有工作已比较 AI 辅助结对编程、传统结对编程和个体学习对学生动机、焦虑、协作学习与编程表现的影响，并进一步从 CHI 研究揭示 AI coding assistants 中 verification load and fatigue 的机制。入职后，我将把这一方向扩展为“AI 辅助学习行为建模与可持续能力培养”研究线，重点回答：

- 学生在使用 AI 编程工具时，哪些交互模式促进概念理解、调试能力和迁移能力，哪些交互模式导致表层完成、能力错觉或学习依赖？
- AI 生成代码或解释之后，学生如何进行验证、修改与反思？验证负担如何影响疲劳、信任、学习收益和长期能力形成？
- 如何设计面向课程场景的 AI 学习助手，使其提供分层提示、反思脚手架、错误诊断和验证支持，而非直接替代学生思考？
- 教师如何在 AI 参与后评价作业质量、学习过程和学生真实能力？如何形成兼顾效率与教育公平的课程治理机制？

技术路线包括课堂部署、受控实验、长期学习日志采集、代码行为建模、学习分析、认知负担测量、访谈与扎根理论、LLM 反馈生成、个性化脚手架和自适应提示策略。系统层面拟构建“反思优先”的 AI 编程学习助手，在提供答案前引导学生进行问题分解、假设表达、错误定位和证据验证；评价层面同时关注任务表现、概念掌握、迁移能力、验证负担、信任校准、协作质量与学习公平。

预期形成面向 CHI、CSCW、FSE、ICSE Education、IJAIED、Computers & Education、International Journal of STEM Education 等方向的持续成果，并为深圳理工的人才培养和课程建设提供可部署、可评价的 AI 教育工具。

方向三：AI 介导沟通、情感规范、隐私同意与信任校准

AI 介入社会互动后，不仅改变信息生成方式，也改变表达真实性、责任归属、情感规范和隐私边界。用户在使用 AI 写消息、生成摘要、解释情绪、表达关怀或进行平台同意选择时，往往并非简单追求“更好文本”，而是在判断何种表达仍属于自己、何种建议值得信任、何种同意是真实偏好、何种系统设计构成操纵。

我已有工作覆盖语言模型中的情感得体性规范、AI 辅助浪漫沟通中的作者归属与真实性、AI 生成摘要中的信任与理解、Web consent 中的同意边界与 opt-out friction。入职后，我拟围绕“AI 介入社会互动后的规范、信任与边界”继续推进，研究以下问题：

- 当 AI 参与撰写消息、表达情绪或生成建议时，用户如何判断作者归属、表达真实性、责任边界和关系风险？
- LLM 在不同角色、机构、文化语境和强度条件下会学习到怎样的情感规范？这些规范是否会放大社会刻板印象、制度性偏差或不平等期待？

- 隐私同意与用户选择在多大程度上反映真实偏好，在多大程度上被默认选项、界面摩擦、暗黑模式和信息不对称塑造？
- 如何设计可解释、可撤回、可审计的 AI 介导沟通和隐私同意机制，使用户在效率、表达质量和主体性之间获得更好平衡？

方法上，将结合情境实验、交互原型、跨文化问卷、访谈、行为日志、LLM 行为测量、界面审计和因果推断；系统上，将开发 AI 介导沟通信任评估工具、隐私同意实验平台和语言模型情感规范审计工具。该方向与中心 AI for Humanity 中关于 AI 对人类个体与群体行为影响的关注高度一致，可为理解 AI 如何重塑社会关系、表达规范和选择行为提供实证基础。

方向四：群体行为、公平偏好学习与资源分配中的福利估计

中心强调群体行为、资源分配与效率之间的关系。现实 AI 系统越来越依赖人类反馈，但这些反馈通常来自非均匀人群、网络结构、平台曝光机制或既有权力关系。如果直接将观察到的反馈等同于“群体偏好”，模型可能系统性忽视边缘群体、沉默用户和低可见度需求，从而在推荐、教育支持、社区响应、科研评价和资源分配中产生不公平后果。

我在 ICML 方向的 Graph-Preference Learning 工作关注网络采样人类反馈中的偏差校正与目标福利估计，在 WWW 方向的算法公平元评估工作关注公平审计结论的可靠性，在 AAAI 方向的在线心理健康社区研究关注低响应用户的支持缺口。这些工作共同构成了将群体反馈、网络结构和福利估计结合的技术基础。

后续拟研究：

- 当反馈来自社交网络、在线社区、科研合作网络或平台流量时，如何识别采样偏差、曝光偏差、沉默偏差和群体代表性不足？
- 如何在目标群体福利估计中同时考虑效率、公平、可解释性和不确定性，避免平均表现掩盖弱势群体风险？
- 如何将图神经网络、偏好学习、反事实评估、分布鲁棒优化、公平约束和人类主观评价结合，形成可审计的群体行为模型？
- 如何将该模型应用于科研资源分配、AI 教育支持、在线心理健康社区响应、平台推荐和公共服务资源配置等场景？

技术路线包括网络采样校正、图表示学习、因果推断、分布鲁棒优化、置信区间与保形预测、差分隐私、群体公平约束和人类实验验证。预期产出包括公平偏好学习算法、群体福利估计工具包、网络采样反馈数据集、面向科研资源分配的模拟与实证模型，以及面向 ICML、NeurIPS、WWW、FAccT、AAAI、TKDE、TOIS 等方向的研究成果。

五、共性方法、平台建设与技术路线

上述四个方向虽然应用场景不同，但共享同一研究范式：以真实行为为入口，以可解释计算模型为核心，以系统原型和群体福利评估为落点。

1. 行为证据采集。 通过受控实验、在线实验、课堂部署、科研任务实测、访谈、问卷、交互日志、代码行为数据、平台数据和多主体模拟，捕捉用户在 AI 系统中的学习、检索、验证、沟通、同意、反馈和资源选择行为。

2. 计算模型构建。 使用 LLM、RAG、Agent workflow、图神经网络、偏好学习、因果推断、行为序列建模、差分隐私、保形预测和公平性约束，将个体行为、网络结构、群体反馈和福利目标转化为可估计、可解释、可审计的模型。

3. 系统原型验证。 构建 AI Scientist 协作原型、AI 编程学习助手、AI 介导沟通信任评估工具、隐私同意实验平台、群体福利估计工具和公平审计仪表盘，并在真实或半真实任务中验证其效果。

4. 多维评价指标。 不以单一准确率或效率指标衡量系统，而是同时评估任务表现、学习收益、认知负担、验证负担、信任校准、错误发现率、创造性、隐私感知、公平感、群体福利、不确定性和长期可持续性。

5. 伦理与治理机制。 对涉及学生、研究者、心理健康社区、隐私同意和群体偏好的数据，建立知情同意、隐私保护、数据最小化、差分隐私或本地化处理、风险告知和可撤回机制，确保研究过程符合伦理规范和社会责任。

六、阶段性实施计划

第一阶段：入职后 1 年内——聚焦定位、搭建平台、形成首批投稿

1. 围绕中心 AI for Science 方向，建立“科研 AI 工具人因评估”实验协议，选择文献综述、研究问题生成、证据验证和审稿判断作为首批任务。

2. 以已有 AI 编程教育和 verification load 研究为基础，开发 AI 编程学习助手或 AI 科研协作原型，完成首轮用户实验。

3. 整合既有 CHI、ACL、ICML、WWW、AAAI、IJ STEM Education 等工作的研究范式、量表、实验协议和代码，形成可复用的方法库。

4. 围绕公平偏好学习和群体福利估计，设计面向科研资源分配或在线社区响应的模型扩展，为基金申请形成清晰技术主线。

5. 申请国家自然科学基金青年/面上项目、广东省自然科学基金、深圳市科技计划及人工智能交叉研究项目。

6. 力争形成 1-2 篇 CCF A 类会议或中科院一区期刊投稿，并完成 1 个可展示系统原型。

第二阶段：第 2-3 年——纵向部署、交叉合作、形成稳定研究组

1. 建立“AI for Science 人因评估”“AI 辅助学习行为建模”“AI 介导沟通信任与隐私”“公平偏好学习与群体福利估计”四个相互支撑的研究模块。

2. 在课程、科研任务、在线社区或平台交互场景中进行纵向部署，积累真实任务数据和长期行为证据。

3. 与中心科研行为、多主体交互、资源分配和社会行为方向开展合作，将我的 HCI 实验、LLM 评估和公平建模方法嵌入中心重点问题。
4. 形成开放数据集、工具包、实验平台或基准任务，例如 AI Scientist 人因评测集、AI 辅助学习行为数据集、隐私同意行为数据集和网络采样偏好学习评测集。
5. 指导硕士生、博士生、本科科研学生和研究助理，逐步形成以 Human-Centered AI、HCI、社会计算和可信机器学习为核心的小型交叉研究组。
6. 力争在 CHI、CSCW、ACL、WWW、FAccT、ICML、AAAI、FSE 及相关一区期刊形成连续发表。

第三阶段：第 4 - 5 年——形成方向品牌、建设平台、扩大国际影响

1. 形成具有辨识度的研究方向：面向科研与社会行为的人本智能系统研究，成为中心 AI 与行为交叉研究中的稳定技术与实验支撑方向。
2. 建成可复用的人本 AI 评估平台，支持 AI Scientist、AI 教育、AI 介导沟通、隐私同意和群体资源分配等多场景实验。
3. 争取国家级、省部级或深圳市重点项目，推动与教育平台、科研平台、在线社区、公共服务平台和科技企业的合作验证。
4. 在国际顶级会议和期刊持续发表高水平论文，推动数据、代码、实验协议和原型工具开放，提升中心在 Human-Centered AI 与行为计算方向的学术可见度。
5. 开设或参与 Human-Centered AI、人机交互、AI 系统评估、AI 与社会计算、可信机器学习等课程，将科研平台转化为人才培养平台。

七、预期成果与中心贡献

学术成果。 3 - 5 年内围绕 AI Scientist 人因评估、AI 辅助学习、AI 介导沟通、隐私同意、公平偏好学习和群体福利估计，力争在 CHI、CSCW、ACL、WWW、FAccT、ICML、AAAI、FSE、TOCHI、IJAIED、TOIS、TKDE 及中科院一区期刊形成系列成果。

系统与平台。 建设 AI Scientist 人因评估平台、AI 编程学习助手、AI 介导沟通信任评估工具、隐私同意实验平台、群体福利估计工具包和公平审计仪表盘，为中心提供可持续复用的实验与系统基础设施。

数据与基准。 形成科研 AI 协作行为数据集、AI 辅助学习行为数据集、AI 介导沟通与信任判断数据集、隐私同意行为数据集、网络采样偏好学习评测集和群体福利估计基准。

项目与合作。 以“AI 参与科研与社会行为后的可信评估与群体福利优化”为主线，申请国家自然科学基金、广东省自然科学基金、深圳市科技计划及人工智能交叉专项，并与中心内部 AI Scientist、群体行为、资源分配和行为建模方向形成合作。

人才培养。 建设跨 HCI、机器学习、社会计算、教育技术和行为科学的小型研究团队，培养学生同时具备用户研究、系统实现、算法建模、实证评估和学术写作能力。

平台贡献。我能够为中心带来三类直接贡献：一是面向真实用户和真实任务的 HCI 实证研究能力；二是面向 LLM、GNN、偏好学习和公平评估的计算建模能力；三是将科研行为、学习行为、沟通行为和群体资源分配连接起来的跨场景系统设计能力。这些贡献有助于中心将宏观的 AI 与行为交叉愿景转化为可检验、可发表、可部署和可持续扩展的研究项目。

八、可行性、风险与应对

本计划具有明确的可行性基础。已有论文和项目证明，我能够在 AI 教育、AI 介导沟通、隐私同意、公平偏好学习、在线社区和图学习等方向持续产出高水平成果；同时，我具备高校教学经验和真实课堂部署基础，能够将学生培养、课程建设和科研实验结合起来。深圳理工大学依托人工智能研究院和深圳先进技术研究院，具有工程转化、交叉学科、应用场景和高水平人才平台优势，为本计划提供了良好的组织环境。

可能风险主要包括：真实科研和平台数据获取难度较高，LLM 系统快速迭代导致实验可复现性下降，跨学科指标难以统一，以及涉及隐私、学生和心理健康场景的数据伦理要求较高。针对这些风险，我将采取以下策略：优先使用可控实验与半真实任务建立稳定范式，再逐步拓展真实部署；在实验中记录模型版本、提示、检索语料和交互过程，保证可追溯性；建立跨任务通用指标与场景化指标并行的评价体系；对敏感数据采用最小化采集、匿名化、本地处理、差分隐私和伦理审查流程。

九、结语

总体而言，我拟在深圳理工大学人工智能研究院“智能与行为交叉研究中心”建设的方向，不是对既有 Human-Centered AI 研究的简单延续，而是围绕中心的 AI for Science 与 AI for Humanity 战略，将我的 HCI 实证研究、LLM 系统评估、公平偏好学习、群体福利估计和真实场景部署经验整合起来，形成“面向科研与社会行为的人本智能系统研究”这一可持续、可协同、可产出高水平成果的学术主线。

这一方向既能够服务中心关于科研行为、群体行为、资源分配和行为建模的核心问题，也能够保持我在 AI 教育、AI 介导沟通、社会计算和可信机器学习方面的独立学术辨识度。入职后，我希望以真实用户和真实任务为起点，系统研究 AI 如何改变人的学习、沟通、科研判断和群体福利，并将这些理解转化为更可靠、更公平、更可解释、更可部署的人本智能系统。