

研究计划

面向情感智能、社会计算与计算心理健康的人本智能系统研究

申请人	樊光瑞
拟申请单位	深圳北理莫斯科大学人工智能研究院
拟申请岗位	教学科研岗教师（副教授/高级讲师；如学校评审认为更适配其他岗位，本人亦愿接受相应岗位评估）
拟对接方向	数字经济与社会计算研究中心；情感智能与普适计算研究中心
计划周期	入职后 3-5 年

一、研究愿景与总体定位

人工智能正在从辅助性工具转变为深度嵌入学习、沟通、情绪表达、在线社区、平台治理、公共服务和社会决策过程的基础性社会技术系统。随之而来的核心问题，不再只是模型能否生成更准确的结果，而是：当 AI 进入真实用户与真实社会场景之后，人如何理解、使用、信任、依赖、抵抗或被其影响；这些行为证据如何被可靠地转化为计算模型；以及如何设计兼顾效率、公平、隐私、信任和心理福祉的人本智能系统。

深圳北理莫斯科大学人工智能研究院强调人工智能原创性基础理论、关键技术、工程应用与大跨度学科交叉融合，招聘方向覆盖自然语言处理、心理学、认知神经科学、智能网络、移动计算、智能系统、数字经济、社会计算和人工智能交叉等领域。研究院下设的数字经济与社会计算研究中心关注数字经济、社会计算、复杂环境人机交互、精神状态智能计算和可持续发展中的数据分析与优化；情感智能与普适计算研究中心关注情感智能、普适计算、脑物移动互联，以及 AI 与心理、精神健康和临床诊疗场景的结合。上述方向与我长期从事的 Human-Centered AI、人机交互、社会计算、AI 教育、AI 介导沟通、计算心理健康、隐私与信任、算法公平和图神经网络研究高度契合。

本计划拟在贵院发展一条具有个人积累、国际发表潜力和平台协同价值的研究主线：**面向情感智能、社会计算与计算心理健康的人本智能系统研究**。该主线以真实用户和真实社会场景为对象，以 HCI 实证研究、LLM、图神经网络、偏好学习、隐私保护和公平机器学习为方法基础，围绕 AI 如何影响人的学习、沟通、情绪表达、心理支持、隐私选择与群体反馈展开系统研究。与纯粹追求模型指标的 AI 研究不同，本计划强调“行为证据—计算建模—系统原型—真实评估”的闭环，力图把人的认知、情感、信任、隐私与福利纳入 AI 系统设计和评价之中。

二、已有研究基础与岗位匹配

我的研究基础可以概括为三个相互支撑的方向。

第一，**AI 辅助学习与人机协作基础**。我围绕 AI 辅助编程教育开展了系列研究，比较 AI 辅助结对编程、传统结对编程和个体学习对学生学习动机、编程焦虑、协作学习与编程表现的影响，并进一步研

究 AI coding assistants 中 verification load and fatigue 的形成机制。这一方向直接支撑贵院在智能系统、交互式教育机器人、人机交互和 AI 教育应用中的研究需求。

第二，**AI 介导沟通、情感规范与信任基础**。我已有工作关注语言模型中的情感得体性规范、AI 辅助浪漫沟通中的作者归属与真实性判断、AI 生成摘要中的信任与理解、Web consent 中的同意边界与退出摩擦。这些研究关注 AI 参与人类沟通和情感表达后，主体性、真实性、情绪规范、信任校准和隐私边界如何被重新定义，能够与情感智能与普适计算研究中心关于情感智能、心理过程建模和普适交互的方向形成自然连接。

第三，**社会计算、公平建模与计算心理健康基础**。我在 Graph-Preference Learning、算法公平元评估、在线心理健康社区回复缺口预测、图神经网络交通预测、隐私保护心理健康筛查和分布无关推荐风险控制等方向开展了机器学习与社会计算研究。相关工作能够支持数字经济与社会计算研究中心在复杂环境人机交互、AI+心理健康、社会计算、推荐系统、群体行为、隐私保护和可持续发展数据分析方面的研究布局。

截至目前，我以第一作者或通讯作者发表或录用 ACL、ICML、CHI、FSE、WWW、AAAI、IJCAI 等 CCF A 类会议论文 9 篇，以及 Q1 / 中科院 1 区 Top 期刊论文 4 篇；其中 3 篇被 CHI 2026 录用，1 篇获得 ACM CHI 2026 Honourable Mention Award；发表于 International Journal of STEM Education 的论文获评 ESI 高被引论文。这些成果说明我已具备持续开展高水平跨学科研究、组织用户实验、进行系统开发与机器学习建模、并将研究成果投稿至国际顶级会议和期刊的能力。

三、核心科学问题与总体目标

本计划围绕“人本智能系统如何在情感、社会与心理健康场景中可信运行”展开，重点回答四个核心科学问题。

问题一：AI 如何改变人的学习、沟通、情绪表达和心理支持行为？ 重点关注 AI 介入后用户的认知负担、验证负担、情感表达、真实性判断、信任校准、隐私选择、社会支持和长期能力形成机制。

问题二：如何将真实用户行为和社会反馈转化为可解释、可审计、可部署的计算模型？ 真实反馈往往来自不均衡人群、社交网络、在线社区、平台曝光、界面摩擦或群体沉默，需要结合实验数据、日志数据、网络结构、问卷访谈、偏好学习、图学习和因果推断进行稳健建模。

问题三：如何在 AI 系统设计中同时兼顾效率、公平、隐私、信任和心理福祉？ 面向教育支持、在线心理健康社区、AI 介导沟通、隐私同意、推荐系统和公共服务场景，需要避免只追求平均性能，而忽视弱势用户、低可见度需求、过度依赖、隐私风险和心理负担。

问题四：如何构建可长期部署、可跨场景迁移的人本智能评估平台？ 需要形成既能服务学术研究、又能支撑研究院平台建设和学生培养的实验协议、数据集、系统原型、指标体系和开源工具。

围绕上述问题，入职后 3-5 年拟实现以下目标：

1. 形成“人本智能与社会计算”稳定研究方向，在 AI 介导沟通、AI 教育、计算心理健康、隐私与信任、群体反馈和公平偏好学习方面持续产出高水平成果。

2. 建设可复用的人本 AI 评估与实验平台，支持用户实验、在线部署、学习行为分析、AI 介导沟通评估、隐私同意实验、心理健康社区建模和群体福利估计。
3. 构建面向情感智能和计算心理健康的 LLM/HCI 交叉研究体系，解释 AI 如何影响情绪表达、社会支持、心理状态识别、信任校准和用户主体性。
4. 发展面向社会计算场景的公平偏好学习、图神经网络和隐私保护方法，为推荐、在线社区响应、教育支持和公共服务资源分配提供可审计模型。
5. 逐步建设由研究生、本科科研学生和科研助理组成的小型交叉研究团队，推动论文发表、项目申请、课程建设和校内外合作。

四、拟开展的研究方向

方向一：AI 介导沟通、情感智能与信任校准

生成式 AI 正在参与人的情感表达、消息撰写、关系维护、信息解释和社会互动。它既可能帮助用户表达复杂情绪、降低沟通成本，也可能带来真实性危机、责任模糊、情感操纵、过度依赖和信任错配。在情感智能与普适计算场景中，真正重要的问题不仅是 AI 能否识别或生成情绪，更是 AI 如何在具体社会关系、文化语境、机构角色和交互情境中影响人的表达、判断与行动。

我拟围绕以下问题开展研究：

- 当 AI 参与消息撰写、情感表达、关系维护或心理支持时，用户如何判断“是否还是本人表达”“作者与责任如何归属”“何种 AI 介入是可接受的”？
- LLM 在不同角色、机构、文化语境和情感强度条件下会形成怎样的情感得体性规范？这些规范是否会放大社会刻板印象、制度性偏差或不平等期待？
- 面向情感智能应用，如何设计可解释、可撤回、可审计的 AI 介导沟通机制，使系统既能增强表达质量，又不削弱用户主体性和关系真实性？
- 如何建立 AI 介导沟通中的信任校准指标，区分合理信任、盲目信任、过度怀疑和误判责任？

技术路线包括情境化实验、跨文化问卷、交互原型、访谈与扎根理论、LLM 行为测量、日志分析、界面审计和因果推断。系统层面将开发 AI 介导沟通信任评估工具、语言模型情感规范审计工具和情感表达辅助原型；评价层面将同时关注表达质量、真实性判断、情绪负担、主体感、责任归属、信任校准和关系风险。

预期产出包括面向 CHI、CSCW、ACL、EMNLP、WWW、ICWSM、TOCHI 和 International Journal of Human-Computer Studies 等方向的论文，以及可用于情感智能系统设计和评估的实验协议与工具。

方向二：AI 辅助学习、教育智能系统与能力形成机制

AI 编程助手、对话式学习助手和智能教育机器人正在进入课堂和家庭学习场景。它们能够提供即时反馈、个性化解释和学习内容推荐，但也可能造成认知卸载、能力错觉、验证疲劳、学习依赖和教育公平问题。贵院公开科研项目中关于交互式投影教育机器人的工作强调人机交互、情景识别、儿童行为与情感识别、智慧云推荐和个性化学习内容推送，这与我已有 AI 编程教育、学习行为建模和人本 AI 评估研究形成良好互补。

我拟重点研究：

- 学生使用 AI 学习助手时，哪些交互模式促进概念理解、问题分解、调试能力和迁移能力，哪些交互模式导致表层完成、过度依赖或能力错觉？
- AI 生成代码、解释或学习建议之后，学生如何验证、修改和反思？验证负担如何影响疲劳、信任和长期学习收益？
- 如何设计“反思优先”的 AI 学习助手，使其提供分层提示、错误诊断、过程反馈和验证支持，而非直接替代学生思考？
- 在儿童教育、编程教育和大学课程中，如何结合情绪/行为识别、学习分析和推荐模型，实现兼顾学习效率、心理负担和教育公平的个性化支持？

技术路线包括课堂部署、受控实验、长期学习日志采集、代码行为建模、学习分析、认知负担测量、访谈、LLM 反馈生成、个性化脚手架和自适应提示策略。系统层面拟构建 AI 编程学习助手和学习行为分析平台，并与教育机器人、移动端学习应用或云端推荐系统形成接口；评价层面同时关注任务表现、概念掌握、迁移能力、验证负担、学习动机、焦虑、信任校准和公平性。

预期产出包括面向 CHI、CSCW、FSE、ICSE Education、IJAIED、Computers & Education、International Journal of STEM Education 等方向的持续成果，以及可在课程中部署的 AI 学习支持原型和学习行为数据集。

方向三：计算心理健康、在线社区支持与隐私保护社会计算

心理健康是情感智能、普适计算和社会计算交叉的重要场景。现实中的心理健康支持不仅发生在医院和实验室，也发生在在线社区、社交媒体、学习平台、移动应用和日常交互中。AI 可以帮助识别风险、推荐支持、缓解回复缺口和提高资源分配效率，但也涉及高敏感数据、污名化风险、误判风险、隐私泄露和责任边界等问题。

我已有在线心理健康社区回复缺口预测、隐私保护心理健康筛查、AI+心理健康社区建模等研究基础。后续拟围绕以下问题展开：

- 在线心理健康社区中，哪些用户和帖子更容易出现“回复缺口”或低质量支持？如何解释并减少这些支持不平等？
- 如何在不暴露敏感文本和身份信息的前提下，进行心理健康风险筛查、社会支持需求识别和社区响应推荐？
- 如何结合 LLM、图神经网络、隐私保护学习和人机协作机制，构建既有帮助性又可审计的心理健康社区辅助系统？
- 普适计算或移动交互场景下，如何将行为信号、用户自报告和社会互动数据结合起来，同时避免过度监测、标签化和算法伤害？

技术路线包括在线社区数据建模、图神经网络、LLM 教师蒸馏、本地差分隐私、低文本或无文本特征表示、用户研究、风险分层、干预模拟和伦理审查机制。系统层面拟构建隐私保护心理健康筛查工具、在线社区回复支持模型和社会支持推荐原型；评价层面不仅关注预测准确率，还关注意释性、隐私保护强度、误伤风险、支持质量、用户接受度和公平性。

该方向能够与数字经济与社会计算研究中心关于社会计算和精神卫生工程技术研究的定位形成较强协同，也能与情感智能与普适计算研究中心在心理状态建模和普适交互方面开展合作。

方向四：公平偏好学习、群体反馈与可信社会计算

AI 系统越来越依赖人类反馈，但真实反馈往往来自不均衡人群、社交网络、平台曝光机制、界面摩擦或既有权力结构。如果直接将观察到的反馈视为“总体偏好”，模型可能系统性忽视边缘群体、沉默用户和低可见度需求，从而在推荐、教育支持、心理健康社区响应、公共服务资源分配和平台治理中产生不公平后果。

我在 Graph-Preference Learning 中研究网络采样人类反馈的偏差校正与目标福利估计，在 WWW 方向工作中研究公平审计结论的可靠性，在推荐风险控制和图神经网络交通预测方面也有相关积累。后续拟发展面向社会计算场景的公平偏好学习与可信决策方法：

- 当反馈来自社交网络、在线社区、教育平台或推荐系统时，如何识别采样偏差、曝光偏差、沉默偏差和群体代表性不足？
- 如何在目标群体福利估计中同时考虑效率、公平、不确定性、隐私保护和可解释性，避免平均表现掩盖弱势群体风险？
- 如何将图神经网络、偏好学习、反事实评估、分布鲁棒优化、保形预测、公平约束和人类主观评价结合，形成可审计的社会计算模型？
- 如何将上述模型应用于教育资源支持、在线社区响应、公共服务推荐、绿色交通和可持续发展数据分析等场景？

技术路线包括网络采样校正、图表示学习、偏好学习、因果推断、分布鲁棒优化、置信区间与保形预测、差分隐私、群体公平约束和人类实验验证。预期产出包括公平偏好学习算法、群体福利估计工具包、网络采样反馈数据集、可信推荐评估基准，以及面向 ICML、NeurIPS、WWW、FAccT、AAAI、TKDE、TOIS 等方向的研究成果。

五、共性方法与平台建设

上述四个方向共享同一研究范式：以真实行为为入口，以可解释计算模型为核心，以系统原型和真实场景评估为落点。

1. 行为证据采集。通过受控实验、在线实验、课堂部署、访谈、问卷、交互日志、代码行为数据、在线社区数据、移动/普适交互数据和多主体模拟，捕捉用户在 AI 系统中的学习、沟通、情绪表达、隐私选择、社会支持、反馈和资源选择行为。

2. 计算模型构建。使用 LLM、RAG、图神经网络、偏好学习、因果推断、行为序列建模、差分隐私、保形预测和公平性约束，将个体行为、网络结构、群体反馈和福利目标转化为可估计、可解释、可审计的模型。

3. 系统原型验证。构建 AI 介导沟通评估工具、语言模型情感规范审计平台、AI 编程学习助手、学习行为分析平台、隐私保护心理健康筛查工具、在线社区支持推荐原型、群体福利估计工具和公平审计仪表盘。

4. 多维评价指标。 不以单一准确率或效率指标衡量系统，而是同时评估任务表现、学习收益、认知负担、验证负担、信任校准、主体感、隐私感知、支持质量、公平感、群体福利、不确定性和长期可持续性。

5. 伦理与治理机制。 对涉及学生、儿童、心理健康社区、隐私同意和群体偏好的研究，建立知情同意、数据最小化、匿名化、本地处理、差分隐私、风险告知、人工复核和可撤回机制，确保研究过程符合伦理规范和社会责任。

六、阶段性实施计划

第一阶段：入职后 1 年内——明确方向、搭建平台、形成首批成果

1. 围绕 AI 介导沟通、AI 辅助学习和计算心理健康建立 2-3 个可持续实验场景，优先选择课程部署、在线任务实验和社区数据建模。
2. 整合已有 CHI、ACL、ICML、WWW、AAAI、IJ STEM Education 等工作的实验协议、量表、代码和数据处理流程，形成可复用的人本 AI 研究方法库。
3. 开发首批系统原型：AI 介导沟通信任评估工具、AI 编程学习助手、隐私保护心理健康筛查原型或在线社区响应支持模型。
4. 围绕公平偏好学习和群体福利估计，设计面向教育支持、在线社区响应或推荐系统的模型扩展，形成基金申请技术主线。
5. 申请国家自然科学基金青年/面上项目、广东省自然科学基金、深圳市科技计划、人工智能交叉研究项目和教育/心理健康相关横向合作项目。
6. 力争形成 1-2 篇 CCF A 类会议或中科院一区期刊投稿，并完成 1 个可展示系统原型。

第二阶段：第 2-3 年——纵向部署、交叉合作、形成稳定研究组

1. 建立“AI 介导沟通与情感智能”“AI 辅助学习与教育智能系统”“计算心理健康与社区支持”“公平偏好学习与可信社会计算”四个相互支撑的研究模块。
2. 在课程、在线社区、移动交互或平台推荐场景中开展纵向部署，积累真实任务数据和长期行为证据。
3. 与数字经济与社会计算研究中心在社会计算、推荐系统、AI+心理健康、绿色交通和可持续发展数据分析方面开展合作；与情感智能与普适计算研究中心在情感智能、普适交互、心理状态建模和教育智能系统方面开展合作。
4. 形成开放数据集、工具包、实验平台或基准任务，例如 AI 介导沟通信任数据集、AI 辅助学习行为数据集、在线心理健康社区支持数据集、隐私保护筛查工具和网络采样偏好学习评测集。
5. 指导硕士生、本科科研学生和研究助理，逐步形成以 Human-Centered AI、HCI、社会计算、计算心理健康和可信机器学习为核心的小型交叉研究组。
6. 力争在 CHI、CSCW、ACL、EMNLP、WWW、FAccT、ICML、AAAI、FSE 及相关一区期刊形成连续发表。

第三阶段：第 4-5 年——形成方向品牌、建设平台、扩大影响

1. 形成具有辨识度的研究方向：面向情感智能、社会计算与计算心理健康的人本智能系统研究。

2. 建成可复用的人本 AI 评估平台，支持 AI 介导沟通、AI 教育、计算心理健康、隐私同意、群体反馈和公平推荐等多场景实验。
3. 争取国家级、省部级或深圳市重点项目，推动与教育平台、在线社区、公共服务平台、医疗健康机构和科技企业的合作验证。
4. 在国际顶级会议和期刊持续发表高水平论文，推动数据、代码、实验协议和原型工具开放，提升研究院在 Human-Centered AI、情感智能、社会计算和可信 AI 方向的学术可见度。
5. 开设或参与 Human-Centered AI、人机交互、AI 系统评估、社会计算、可信机器学习、AI 与心理健康等课程，将科研平台转化为人才培养平台。

七、预期成果与平台贡献

学术成果。 3-5 年内围绕 AI 介导沟通、情感智能、AI 辅助学习、计算心理健康、隐私保护、公平偏好学习和可信社会计算，力争在 CHI、CSCW、ACL、EMNLP、WWW、FAccT、ICML、AAAI、FSE、TOCHI、IJAIED、TOIS、TKDE 及中科院一区期刊形成系列成果。

系统与平台。 建设 AI 介导沟通信任评估工具、语言模型情感规范审计平台、AI 编程学习助手、学习行为分析平台、隐私保护心理健康筛查工具、在线社区支持推荐模型、群体福利估计工具包和公平审计仪表盘。

数据与基准。 形成 AI 介导沟通与真实性判断数据集、语言模型情感规范评测集、AI 辅助学习行为数据集、在线心理健康社区支持数据集、隐私保护心理健康筛查评测集、网络采样偏好学习数据集和可信推荐评估基准。

项目与合作。 以“人本智能与社会计算”为主线申请国家自然科学基金、广东省自然科学基金、深圳市科技计划和人工智能交叉专项，并积极对接教育智能、心理健康、社会计算、绿色交通和可持续发展应用场景。

人才培养。 建设跨 HCI、机器学习、社会计算、教育技术、心理健康和行为科学的小型研究团队，培养学生同时具备用户研究、系统实现、算法建模、实证评估和国际学术写作能力。

对研究院的贡献。 本人能够为贵院带来三类直接贡献：一是面向真实用户和真实任务的 HCI 实证研究能力；二是面向 LLM、GNN、偏好学习、隐私保护和公平评估的计算建模能力；三是将情感智能、社会计算、AI 教育和计算心理健康连接起来的跨场景系统设计能力。这些贡献有助于将研究院的人工智能交叉愿景转化为可检验、可发表、可部署和可持续扩展的研究项目。

八、可行性、风险与应对

本计划具有明确的可行性基础。已有论文和项目证明，我能够在 AI 教育、AI 介导沟通、隐私同意、公平偏好学习、在线心理健康社区和图学习等方向持续产出高水平成果；同时，我具备高校教学经验和真实课堂部署基础，能够将学生培养、课程建设和科研实验结合起来。深圳北理莫斯科大学人工智能研究院具有国际化、开放和交叉融合的学术环境，并在情感智能、普适计算、社会计算、AI+心理健康和智能系统方面形成研究平台，为本计划提供了良好的组织环境。

可能风险主要包括：真实平台和心理健康数据获取难度较高，LLM 系统快速迭代导致实验可复现性下降，跨学科指标难以统一，以及涉及学生、儿童、心理健康和隐私场景的数据伦理要求较高。针对这些风险，我将采取以下策略：优先使用可控实验与半真实任务建立稳定范式，再逐步拓展真实部署；在实验中记录模型版本、提示、交互过程和数据处理流程，保证可追溯性；建立跨任务通用指标与场景化指标并行的评价体系；对敏感数据采用最小化采集、匿名化、本地处理、差分隐私、人工复核和伦理审查流程。

九、结语

总体而言，我拟在深圳北理莫斯科大学人工智能研究院建设的研究方向，不是对既有 Human-Centered AI 研究的简单延续，而是面向贵院情感智能、普适计算、数字经济、社会计算和 AI+心理健康等方向，将我的 HCI 实证研究、LLM 系统评估、公平偏好学习、图神经网络、隐私保护和真实场景部署经验整合起来，形成“面向情感智能、社会计算与计算心理健康的人本智能系统研究”这一可持续、可协同、可产出高水平成果的学术主线。

入职后，我希望以真实用户和真实任务为起点，系统研究 AI 如何改变人的学习、沟通、情绪表达、心理支持、隐私选择和群体福利，并将这些理解转化为更可靠、更公平、更可解释、更可部署的人本智能系统，为深圳北理莫斯科大学人工智能研究院的学科建设、人才培养和国际影响力提升贡献力量。